Automatisations LANCE : interface et premier essai règles / Qwen

Du catalogue de procédures à une comparaison guidée sur S1

Projet LANCE

Dernière révision : 2026-10-15 20:25 (Europe/Brussels, UTC+02:00)

Implémentation livrée ; essai exploratoire réel, une seule paire comparable

Résumé

L'interface doit permettre de choisir une procédure, suivre ses étapes et lire ses résultats, puis de distinguer cette exécution d'une mesure comparative de sécurité. Le travail du 15 octobre 2026 a livré un catalogue intégré, un inventaire de services TCP, un historique consultable et le parcours « Comparer règles / LLM ». Ce dernier réutilise les phases d'analyse et de vérification, restaure le scénario avant chaque méthode et conserve les échecs. Après rétablissement de l'accès à Qwen 3.8 27B et suppression des plafonds de coût et de durée dans ce parcours, une paire S1 s'est achevée : F1 des confirmations 84,6 % pour les règles et 88,9 % pour Qwen, avec respectivement 11 et 12 vrais positifs, et trois faux positifs chacun. Qwen a utilisé davantage d'appels et de temps. Ce résultat décrit cet essai seulement : la restauration n'est attestée que dans le périmètre des contrôles effectués, et les preuves n'ont pas encore fait l'objet d'une adjudication expérimentale indépendante.

Table des matières

1 Question, vocabulaire et méthode **2**

2 Interface et procédures effectivement livrées **3**

3 Protocole guidé, limites et corrections du runtime **4**

4 Journal des essais et incidents **5**

5 Résultats de la paire complète S1 **6**

6 Discussion, limites et suites expérimentales **7**

7 Reproduction et sources primaires **8**

Références **8**

1 Question, vocabulaire et méthode

1.1 Ce que l'on cherche à mesurer

La question est : à outils et entrées publiques communs, quelles différences observe-t-on entre une automatisation à règles et une politique assistée par un modèle de langage (LLM) pour l'audit autorisé d'un réseau d'objets connectés (IoT) ? Le laboratoire Proxmox héberge les machines ; le contrôleur LANCE orchestre les outils et les décisions. Un script n'est donc pas à lui seul une méthode d'analyse ou une expérience.

Un *outil* réalise une action technique ; une *procédure* orchestre des étapes ; une *politique* choisit les contrôles et leurs suites. Un *scénario* décrit le laboratoire. Une *paire* rassemble deux audits préparés selon le même protocole. Un inventaire de ports ne mesure pas la qualité d'un audit de vulnérabilités.

D1 désigne l'automatisation conditionnelle sans LLM (rules) ; **A1** utilise la même base déterministe, complétée par les décisions du LLM (llm). Les règles réagissent déjà aux observations. La paire porte sur les phases 3 et 4, analyse et vérification, et non sur les six phases du pipeline complet [1, 2].

1.2 Trois niveaux de preuve distincts

1. **Revue initiale.** Trois revues spécialisées cybersécurité, réseau et expérience utilisateur ont examiné le code au commit 73369b0. La synthèse de 11 :35 proposait un catalogue et un contrôleur de paire ; elle n'avait exécuté aucun audit. Ses 133 puis 35 tests simulés et sa relecture de six pages sont conservés comme provenance historique dans le registre.
2. **Validation logicielle.** Les implémentations successives ont été revues, testées et déployées sur Dev 1. La révision applicative finale est b8a415ab428a9eb8b3e064f17d8178315bb129c7. Sa CI (intégration continue) est réussie avant le dernier lancement réel : 3 972 tests réussis, deux ignorés et deux avertissements en 460,04 secondes [6].
3. **Observation réelle.** L'inventaire puis les cinq tentatives de paire ont été lancés depuis l'interface du laboratoire nato. Une seule paire est complète et déclarée comparable par le protocole. Les métriques proviennent de ses artefacts, pas des tests simulés [7].

Le registre lancement-automatisations-sources.json sépare l'ancienne revue de la révision actuelle. Le fichier lancement-automatisations-resultats.json conserve configurations, identifiants, empreintes et mesures agrégées. Les gros artefacts restent sur nato ; une empreinte identifie leur export sans en attester la validité scientifique. Aucune campagne répétée n'a été menée ici.

2 Interface et procédures effectivement livrées

2.1 Un parcours depuis l'objectif

La zone **Automatisations** comprend les résultats des exécutions, une nouvelle exécution et **Comparer règles / LLM**. L'utilisateur choisit une procédure, renseigne sa cible, examine les effets et lance. Les étapes, paramètres, erreurs, résultats et liens restent consultables dans l'historique. Le catalogue serveur décrit version, empreinte de l'implémentation, dépendances, portée, effets et sorties. Une relance produit un nouvel identifiant [3].

Procédure intégrée	Travail effectué	Portée et effets annoncés
Découvrir les équipements	Sondes Nmap sur un réseau IPv4 autorisé.	Hôtes qui répondent ; aucun score de vulnérabilités.
Inventorier les services	Découverte puis identification sur 21 ports TCP prédéfinis.	Jusqu'à 16 hôtes observés ; autres ports et hôtes silencieux hors couverture.
Auditer un scénario automatiquement	Préparation, analyse et vérification par règles.	Scénario public déployable ; préparation pouvant supprimer les scénarios présents ; contrôles actifs possibles.
Vérifier le lancement hors ligne	Diagnostic d'événements et d'enregistrement.	Aucun accès réseau, appel modèle ou résultat de sécurité.

Table 1 – Catalogue livré. TCP désigne ici les services accessibles par connexions réseau de ce type ; UDP n'est pas couvert par l'inventaire.

Les outils existants sont encapsulés dans les procédures ; l'import libre de scripts ou de commandes n'a pas été ajouté. Les limites par défaut des procédures ordinaires restent distinctes de la comparaison guidée. Les interruptions et résultats partiels restent visibles ; une absence de mesure n'est pas un zéro.

2.2 Inventaire réel et lecture des résultats

Le run 2026-10-15_123829_42ecb36bbe68 a observé quatre hôtes et dix services TCP en cinq appels et 165,87 secondes, sur 192.168.100.0/28. Il vérifie le chemin lancement–étapes–inventaire. Son artefact ne conserve pas d'identifiant de scénario : le contexte opérateur S1 ne suffit pas à en faire un résultat de benchmark S1. Les dix services de cet inventaire ne sont pas les douze vulnérabilités attendues de la paire finale.

L'historique des procédures présente les sorties opérationnelles. La comparaison présente séparément vrais et faux positifs, failles manquées, précision, rappel, F1, appels, erreurs, temps et consommation modèle. Les écarts ne s'affichent que pour une paire comparable ; un contrôle sans faille attendue utilise la spécificité lorsqu'elle est définie. Le résultat peut être rouvert par lien et exporté en JSON (format de données structurées).

3 Protocole guidé, limites et corrections du runtime

Le contrôleur réutilise le pipeline et compare_runs, plutôt que de créer un autre calcul de score [4, 5]. Il réserve le laboratoire partagé, vérifie la cible nato/pve-nato, puis :

1. fige le scénario public, l'inventaire public, l'ordre des méthodes et les paramètres communs ; les données de vérité terrain ne sont pas une entrée des politiques ;
2. supprime puis redéploie les ressources du scénario avant chaque méthode, exécute injection et vérifications des playbooks, puis contrôle la surface TCP publique ;
3. lance les phases 3–4 de chaque méthode avec le profil full, les mêmes outils et validateurs, et exige l'égalité des observations TCP des deux précontrôles ;
4. nettoie le laboratoire, puis charge la vérité terrain après les deux audits, évalue les artefacts, persiste l'issue finale et libère la réservation.

Ce chemin est limité aux scénarios publics compatibles avec la surface TCP prise en charge. Une égalité de hash de définition ne prouve pas l'égalité de l'état vivant. Les vérifications du playbook et des ports ne certifient pas toutes les permissions, données et propriétés de sécurité attendues.

3.1 Ce que signifiaient les limites de ressources

Les premiers formulaires imposaient 200 appels, 600 secondes et 2 dollars de consommation modèle estimée par audit. Ces plafonds pouvaient interrompre la vérification avant ses résultats. Le dernier parcours guidé envoie max_duration_s=null et max_cost_usd=null, sans plafond implicite de dix minutes par équipement. L'activation explicite comparison_unlimited=true reste propre à cette comparaison ; les autres contrats conservent leurs règles de limites existantes.

Le nombre maximal d'appels demeure réglable de 1 à 2 000. Il a été fixé à 2 000 pour les deux méthodes dans l'essai final. Les délais techniques d'une requête réseau, les limites internes des tours du modèle et l'arrêt manuel subsistent. L'absence de plafond de coût ou de durée ne signifie donc pas une exécution sans aucune borne technique. Les anciens runs affichent leurs vrais paramètres historiques.

3.2 Corrections et vérifications

Une correction garde la réservation jusqu'au nettoyage, à l'évaluation et à la publication de l'état final. Elle évite de déclarer le laboratoire disponible pendant cette finalisation et empêche un ancien worker de terminer une nouvelle opération. Un déploiement intermédiaire a été arrêté par le garde de laboratoire occupé ; cette observation a conduit au correctif 711f966.

La révision b8a415a a passé 126 tests ciblés, dont une paire simulée avec plafonds absents et la préservation des contrats bornés ordinaires, puis la suite CI complète citée en section 1. Le formulaire déployé, le suivi et le tableau final ont été vérifiés dans un navigateur. Ces tests ne valident ni chaque oracle de sécurité ni une performance expérimentale.

4 Journal des essais et incidents

La table 2 conserve toutes les tentatives de paire du 15 octobre. Les identifiants sont en UTC ; les heures montrées par l'interface sont celles de Bruxelles (UTC+02 :00). Ces relances de mise au point ne sont pas des répétitions indépendantes d'une campagne préenregistrée. Toutes déclarent un nettoyage réussi.

Début UTC ; suffixe de paire	Modèle et plafonds	Issue et interprétation
13 :30 :25 2ae16f333149	Qwen ; 200 appels, 600 s, 2 USD	Connexions modèle en échec ; zéro token, bras partiel. Non comparable ; aucun F1 Qwen interprétable.
14 :02 :13 cadeb8a36a7e	MiniMax, sélection erronée ; 200, 600 s, 2 USD	Erreur HTTP 402. Modèle rejeté par l'utilisateur ; essai exclu des résultats Qwen.
15 :15 :17 325e8127a530	Qwen ; 200, 600 s, 2 USD	Les quatre équipements sont analysés ; arrêt pendant la vérification au plafond de 600 s. Non comparable.
15 :34 :27 21bd35c5f538	Qwen ; 200, 1 200 s, 2 USD	Dix-neuf candidats proposés ; vérification incomplète au plafond de 1 200 s. Non comparable.
16 :57 :09 11c3405c5607	Qwen ; 2 000 appels, durée et coût sans plafond	Deux bras complets, nettoyage réussi, comparaison admissible selon les contrôles du protocole.

Table 2 – Préfixe commun des identifiants : 2026-10-15_, suivi de l'heure HHMMSS, d'un souligné et du suffixe donné. Les USD sont des plafonds historiques sur une estimation, pas une facture observée.

4.1 Accès à Qwen 3.8 27B

Le relais du fournisseur ollama-umons sur pve-nato ne répondait plus. L'opérateur a constaté l'absence d'écoute sur le port 11435 puis rétabli le tunnel SSH vers le service UMONS. Le catalogue des modèles et une réponse minimale de Qwen ont ensuite été vérifiés ; les tentatives suivantes ont effectivement consommé des tokens. La procédure de référence est conservée dans le guide UMONS, sans mot de passe ni clé dans cette étude [8].

La sélection intermédiaire de MiniMax est une erreur opératoire conservée pour la traçabilité ; elle ne constitue ni un remplacement autorisé de Qwen ni une observation de sa qualité. Le tunnel rétabli manuellement ne démontre pas une persistance après redémarrage. Aucune intervention de ce travail ne cible le homelab personnel.

Les deux arrêts sur durée montrent que ces plafonds ont empêché ces runs d'aboutir. Ils ne prouvent pas que la seule suppression des plafonds cause le score final : les générations, le nombre d'appels autorisés et la version applicative ont aussi varié. Aucun score manquant n'est imputé à zéro.

5 Résultats de la paire complète S1

Paire 2026-10-15_165709_11c3405c5607, lancée depuis Dev 1 après CI réussie, sur la révision b8a415a. Scénario S1, réseau plat 192.168.100.0/24 : routeur, courtier MQTT (messagerie), serveur web et serveur SSH (accès distant). Les règles ont été exécutées en premier. Les précontrôles des deux méthodes sont valides dans leur portée et partagent le même hash d'inventaire TCP observé [7].

Mesure	Règles D1	Qwen A1
Vrais positifs confirmés (TP)	11	12
Faux positifs confirmés (FP)	3	3
Failles attendues manquées (FN)	1	0
Précision des confirmations	78,6 %	80,0 %
Rappel des confirmations	91,7 %	100,0 %
F1 des confirmations	84,6 %	88,9 %
Preuves confirmées marquées invalides	0	0
Appels d'outils	73	132
Erreurs d'outils	0	0
Durée de l'audit	179,8 s	1 239,9 s
Tokens modèle	0	1 029 775
Tours modèle	0	60
Estimation générique de consommation LLM (USD)	0	1,141787

Table 3 – Étage confirmed du comparateur. Les pourcentages sont affichés à une décimale depuis les métriques archivées. La spécificité est non définie pour cette paire.

La précision vaut $TP/(TP+FP)$, le rappel $TP/(TP+FN)$ et $F1 = 2TP/(2TP+FP+FN)$. Le gain descriptif de F1 est de 4,3 points. Qwen confirme une vulnérabilité attendue supplémentaire ; les trois faux positifs persistent. Un rappel de 100 % n'implique donc pas un audit sans erreur. Les zéro preuves marquées invalides reflètent les validateurs automatiques, pas une expertise indépendante de chaque trace.

Le bras règles est 2026-10-15_185920, le bras Qwen 2026-10-15_190434. Qwen a proposé 17 candidats et terminé la vérification ; le comparateur ne signale aucun motif d'incomparabilité. La paire va de 18 :57 :09 à 19 :25 :33, heure de Bruxelles, soit environ 28 min 24 s avec préparation et nettoyage. Les durées du tableau concernent uniquement les audits. Qwen prend environ 6,9 fois le temps des règles et 59 appels supplémentaires.

L'estimation de 1,141787 USD n'est pas une facture UMONS. L'artefact LLM indique cost_is_estimate=true ; ce calcul générique dépend des comptages de tokens et ne mesure ni l'infrastructure, ni le développement, ni la revue humaine. Il ne s'agit pas d'un plafond réintroduit.

6 Discussion, limites et suites expérimentales

6.1 Ce que cet essai établit

L'exécution réelle vérifie qu'un utilisateur peut lancer une paire depuis l'interface, suivre les étapes et obtenir les deux audits, le nettoyage et un tableau comparatif persistant. Dans ce cas S1, la politique Qwen obtient un meilleur F1 de confirmations au prix d'un temps et d'un nombre d'appels plus élevés. Le statut logiciel « comparable » est une décision du protocole courant, dans son périmètre de vérification explicite.

6.2 Ce qu'il reste à établir

— **Validité des constats.** La vérité terrain et les validateurs automatiques n'ont pas été adjudiqués indépendamment pour cette paire. Les faux positifs et le désaccord D1/A1 exigent une lecture des observations brutes et de l'état de référence, avec procédure commune et si possible en aveugle.
— **État initial.** La recréation, les playbooks et la surface TCP apportent des observations, mais pas une certification exhaustive des permissions, versions, configurations et états internes. Les empreintes déclaratives ne remplacent pas ces vérifications.
— **Attribution et variabilité.** Un ordre fixe règles–LLM, un seul scénario public, une seule paire complète et plusieurs relances après incidents ne permettent ni intervalle de confiance ni conclusion générale. La version exacte des poids servis par l'alias qwen3.8:27b n'est pas figée par cet alias seul. Aucun bras supplémentaire n'isole l'adaptation du modèle.
— **Compétence et généralisation.** Règles et prompts contiennent des connaissances des simulateurs du laboratoire. Le résultat ne compare pas Qwen à toute automatisation possible ni à des scénarios réservés. Une comparaison de phases 3–4 n'est pas une évaluation de tout LANCE.
— **Couverture et ressources.** Aucun contrôle sain supplémentaire, aucune autre famille et aucun impact sur un réseau de production n'ont été mesurés. Le plafond d'appels est commun mais la consommation effective diffère. Le réglage de 2 000 appels n'est pas une preuve d'équité universelle des ressources.

La prochaine expérience doit fixer avant exécution les versions, variantes, ordres, répétitions, critères de preuve et marges utiles. Elle doit inclure cas sains et familles pertinentes, conserver tous les échecs et faire relire les preuves. Les améliorations éventuelles de D1 doivent être gelées avant les variantes réservées. Les plafonds de coût et de durée ne sont pas nécessaires au parcours guidé demandé ; les consommations restent des observations utiles.

6.3 Conclusion

Le catalogue et la comparaison guidée répondent au problème de lancement et de lisibilité. Le premier essai S1 complet fournit un contraste descriptif favorable à Qwen sur le F1 des confirmations, avec davantage de ressources consommées. Il justifie l'examen des preuves et une campagne préparée ; il ne démontre pas une supériorité générale du LLM. Garder les règles ou réserver le modèle à certaines tâches reste une conclusion expérimentale recevable.

7 Reproduction et sources primaires

Pour retrouver l'observation, ouvrir le lien de paire dans l'interface Dev 1 ou son export /api/comparisons/2026-10-15_165709_11c3405c5607/download. Les artefacts restent sous output/policy_comparisons/ et output/agent/ sur nato. Les droits et la disponibilité du laboratoire sont nécessaires ; aucun run n'est relancé par la lecture de cette étude.

Pour reproduire un nouvel essai, utiliser la révision applicative indiquée, vérifier nato et le fournisseur UMONS, choisir S1, Qwen 3.8 27B, règles d'abord, 2 000 appels et les plafonds de coût/durée absents. Vérifier le scénario avant chaque méthode et conserver les nouvelles traces sous de nouveaux identifiants. Une relance ne doit pas être attendue au même score. Le registre JSON fournit les empreintes complètes, paramètres et références de CI ; les exports bruts ne sont pas ajoutés à Git.

Références

[1] LANCE, *Protocole scientifique D1/A1*, research/2026-09-27-agent-vs-automation/protocol.md. Les extensions de campagne restent proposées.

[2] LANCE, *Comparaison règles / agent : premier incrément logiciel*, docs/benchmark/agent-vs-automation-cli.md, version au commit b8a415a.

[3] LANCE, src/agent/procedures.py, src/agent/run_modes.py, src/api/routes/procedures.py, src/api/procedure_runs.py et src/static/procedures.js, commit b8a415a.

[4] LANCE, src/benchmark/policy_pair_runner.py, src/api/routes/comparisons.py, src/static/comparisons.js et docs/benchmark/agent-vs-automation-campaign.md, commit b8a415a.

[5] LANCE, src/benchmark/compare_policies.py, src/agent/audit_experiment.py, src/agent/pipeline.py, src/agent/phases/analysis/devices.py, commit b8a415a.

[6] LANCE, workflow GitHub Actions de validation et déploiement Dev 1, run 38768357489, commit b8a415ab428a9eb8b3e064f17d8178315bb129c7, 15 octobre 2026.

[7] LANCE, export réel de la paire 2026-10-15_165709_11c3405c5607, 15 octobre 2026, résultat Dev 1. Agrégats et empreintes : lancement-automatisations-resultats.json ; provenance et revue : lancement-automatisations-sources.json et validation.md du présent dossier.

[8] LANCE, *Accès aux modèles UMONS*, docs/guides/umons-llm.md, procédure consultée le 15 octobre 2026.