Mesurer la valeur marginale des LLM face à des audits simples

Diagnostic de D1 et six expériences hors ligne pour LANCE

Étude LANCE — rédaction assistée par Codex

Dernière révision : 2026-10-07 14:43 (Europe/Brussels, UTC+02:00)
Statut : recherche exploratoire et protocoles proposés ; aucun résultat comparatif

Résumé

Le comité de thèse demande d'établir ce que des méthodes simples sans modèle de langage accomplissent déjà, puis de mesurer le bénéfice de l'ajout du modèle. Une lecture statique du dépôt montre un socle déterministe partagé et une référence D1 conditionnelle, limitée à l'analyse et à la vérification. Les autres comparateurs du protocole restent proposés ; les conflits de la copie locale empêchent de présumer une exécution actuellement valide. Six expériences sur observations et configurations fournies sont définies : routine, faible prévalence, autorisation, information répartie, variations équivalentes et restitution humaine. Elles séparent interprétation et collecte, comparent des références simples crédibles, prévoient un oracle indépendant et conservent les échecs. La décision peut être de garder les règles, d'utiliser le LLM seulement pour une tâche délimitée, ou de conclure à une incertitude. Aucune marge métier, taille d'échantillon ou performance n'est encore validée.

Table des matières

1 Question, périmètre et méthode **1**

2 Constats : ce que couvre réellement la référence D1 **2**

3 Comparateurs simples et attribution de l'effet **3**

4 Protocole commun aux six expériences proposées **4**

5 Mesures, décision et séquence réaliste **7**

6 Limites et conclusion **8**

Références **9**

1 Question, périmètre et méthode

La question est : **pour quelles tâches le modèle apporte-t-il un gain utile au-delà d'une méthode simple correctement conçue, à quel coût et avec quelles erreurs ?** L'Internet des objets est abrégé IoT ; un modèle de langage est abrégé LLM. Un audit peut réussir grâce à des outils et règles communs : sa réussite absolue ne démontre pas une contribution du modèle.

Cette étude prolonge le protocole du 27 septembre [1] et répond à la demande de comparateurs plus simples. Elle porte d'abord sur des dossiers enregistrés ou des configurations documentées, sans nouvelle action sur des systèmes. Les expériences sont des *propositions*, non des résultats. Elles ne mesurent ni découverte autonome, ni réussite d'intrusion, ni couverture d'un réseau inconnu. Aucun audit de laboratoire ou appel au LLM applicatif n'a été exécuté pour cette recherche.

La méthode associe lecture des index, des protocoles et des guides CLI/campagne, inspection des modules cités au tableau 1, et recherche méthodologique primaire ciblée. La tête Git consultée est `a8dbeb9404f0cad960d61e42f02a1d70ca143a59`, avec modifications locales et conflits : ce SHA ne suffit pas à identifier le contenu lu. Le fichier `sans-llm-experiences-sources.json` conserve les empreintes des modules inspectés et les périmètres de lecture des références externes, consultées le 7 octobre 2026. Les résultats historiques de tests mentionnés dans les guides n'ont pas été reproduits. Aucune importation applicative n'a été tentée.

Les cinq références méthodologiques concernent l'attribution causale, l'indépendance des observations, l'équivalence, les oracles de test et la maintenance. La lecture est ciblée : sections précisées aux références, sans reproduction des articles. Le transfert de ces principes à LANCE est *notre proposition* ; les sources ne valident aucun gain de LANCE.

2 Constats : ce que couvre réellement la référence D1

2.1 Un socle réel, mais un périmètre restreint

D1 désigne l'automatisation conditionnelle sans LLM ; A1 désigne l'agent adaptatif avec LLM. Le contrat expérimental disponible fixe un inventaire public commun, le profil `full`, un worker et les phases 3–4 : analyse puis vérification. La reconnaissance et la rédaction ne font pas partie de ce contraste. En phase 3, les deux politiques utilisent d'abord le scanner déterministe ; D1 évite ensuite l'analyse par agents LLM. Les sources visibles étayent cette organisation, pas une qualité empirique des résultats.

TABLE 1 – Diagnostic statique de la copie consultée ; aucun taux de réussite n'est déduit.

Objet et fichier	Fait visible	Limite pour la comparaison
Entrée et périmètre `audit_experiment.py`	Valide l'inventaire public ; impose `full`, phases 3–4 et plafonds ; version D1 v2 (identifiant complet ci-dessous).	Texte public et rôle peuvent révéler une solution ; l'empreinte d'environnement reste déclarative.
Phase 3 `analysis/scan.py`, `analysis/devices.py`	Scanner et suivis déterministes communs ; les agents d'analyse sont évités en `rules`.	L'apport d'A1 est un ajout au socle. Les observations finales d'A1 peuvent donc différer de celles de D1.
Extraction `scanner.py`, `analysis/aggregation_loading.py`	Extracteurs HTTP, MQTT, SSH, FTP, Redis, SNMP, CoAP, API/PKI/OTA/cloud/OT ; filtres de promotion selon profil et rôle.	Présence d'un extracteur ≠ couverture démontrée. Certaines règles dépendent des simulateurs et de rôles connus.
Phase 4 `verification/rules.py`	Plan préexistant ; une reprise admissible et une lecture HTTP complémentaire au plus ; trois appels au maximum par candidat dans cette boucle.	Le plafond exclut les scans de phase 3. Un plan absent donne un cas non pris en charge, pas une conclusion saine.
Comparaison `compare_policies.py`, `policy_campaign.py`	Vérifie identité déclarée, artefacts et contrats ; conserve essais prévus et coûts observés, sépare paires admissibles.	Pas d'intervalle par famille ; coût LLM partiel ; égalité des déclarations ≠ état réel identique.

La version déclarée des règles est `shared-scanner-bounded-verification-v2`. En phase 4, D1 reprend une opération répétable après une erreur transitoire reconnue. Il peut remplacer une lecture

HTTP insuffisante par une réponse structurée sur la même URL. Il s'arrête sur confirmation, refus, erreur non admissible ou preuve toujours insuffisante. Les verdicts utilisent le synthétiseur de preuve commun. D1 est donc plus qu'un script linéaire, mais ne représente pas toutes les méthodes classiques d'audit.

2.2 Ce qui ne doit pas être annoncé comme acquis

Des extracteurs couvrent déjà des autorisations API et des relations PKI. Ce constat interdit de supposer que toute combinaison d'informations nécessite un modèle. Il ne prouve pas que les cas nouveaux seront correctement traités. Il faut distinguer l'existence d'une règle, son déclenchement, la production d'un candidat, sa promotion et la preuve finale admise. La phase d'analyse locale contient aussi un helper de compatibilité CVE, mais le chemin inspecté de `analysis/scan.py` l'appelle sous condition `compact_local`. Cela ne démontre pas sa couverture dans l'expérience imposant `full` ; il ne s'agit pas d'une preuve d'absence universelle de contrôle CVE.

Les fichiers `src/benchmark/metric_contract.py`, `src/agent/exploit_evidence.py` et `src/agent/phases/verification/run.py` contiennent des marqueurs de fusion. Les deux branches déclarent respectivement des contrats de mesure `strict-v3.16/strict-v3.15` et de preuve `evidence-v15/evidence-v14`. Aucun contrat unique n'est retenu ici. Une analyse syntaxique statique sous Python 3.11.9 échoue aux marqueurs de deux modules ; elle ne teste pas le runtime cible Python 3.12. Les validations historiques ne garantissent donc pas l'importabilité actuelle. La remise en état et les tests ciblés constituent une précondition d'une future expérience intégrée, pas un travail réalisé dans cette recherche.

D0 (procédure fixe), A0 (plan LLM initial ensuite figé) et D1-R (D1 avec rédaction par LLM après clôture technique) sont documentés comme propositions. Le manifeste de 24 bras est une préparation, sans preuve de campagne réalisée. Les six expériences suivantes n'utilisent pas ces nombres comme effectif validé.

3 Comparateurs simples et attribution de l'effet

3.1 Construire une référence crédible avant d'ajouter de la complexité

Le tableau 2 conserve les noms du protocole. Pour les expériences hors ligne, « interpréteur à règles » et « interpréteur LLM » sont des lecteurs de dossiers, pas des nouveaux noms pour D1 et A1. L'étude de méthodes d'audit du 7 octobre utilise séparément E0, E1 et E2 pour des représentations de preuves ; ces identifiants ne sont ni renommés, ni assimilés à D0/D1/A0/A1.

Table 2 – Ordre proposé des comparateurs ; les lecteurs hors ligne restent distincts des contrôleurs.

Référence	Définition intelligible	Question et priorité
D0	Procédure fixe, sortie structurée et règles de constat prédéfinies.	Établir ce qui fonctionne sans adaptation ; référence secondaire.
D1	Règles conditionnelles, état observable, reprises bornées et arrêt explicite.	Référence principale. Renforcer les lacunes connues sur développement, sans voir l'oracle du test.
Lecteurs	Même dossier normalisé, règles contre LLM, sans outil supplémentaire.	Premier contraste pour l'interprétation ; décrit séparément du pipeline interactif.
D1-R	Mêmes résultats techniques D1, rapport rédigé par LLM après gel.	Expérience de restitution ; aucun gain de détection attribuable au rapport.
A0/A1	Plan LLM figé contre agent adaptatif.	Contraste ultérieur si le besoin de décision interactive est établi ; non testé ici.

La priorité est une table de règles et une normalisation commune, avec une matrice de couverture lisible : propriété, données requises, cas pris en charge, motif d'abstention et tests positifs/négatifs. Des jointures relationnelles simples ou une politique d'accès explicite sont ajoutées seulement si les cas exigent ces informations. Une règle dépendant de l'identifiant privé d'un scénario est inadmissible. Une règle métier publique accordée au LLM doit également être disponible au comparateur simple.

Avant le gel, un relecteur différent des auteurs examine les lacunes réparables de D1 et les connaissances liées aux simulateurs. Archiver les heures de développement des règles, des parseurs, des prompts et de leurs essais. Le test final reste inaccessible à ces auteurs. Une comparaison avec un outil externe mesure ensuite l'utilité de systèmes complets ; des différences de couverture ou de collecte empêchent d'attribuer tout l'écart au LLM.

3.2 Trois effets à ne pas mélanger

La première question est l'interprétation : même information, même format accessible, même propriété attendue et même budget d'analyse ; seule la méthode de lecture change. La seconde concerne le choix d'observations dans une future expérience intégrée. La troisième est le travail humain de restitution. La distinction entre effet d'une intervention définie et association motive ces contrastes ; notre application au logiciel est une adaptation méthodologique de la discussion sur la randomisation de Hernán et Robins [2].

Un dossier construit uniquement à partir des candidats de LANCE manque les cas que le pipeline n'a jamais proposés. L'échantillonnage doit partir des propriétés et configurations indépendantes, puis inclure cas détectés, non détectés, sains et indéterminés. Quand des observations proviennent d'un run A1 historique, préciser leur provenance : une comparaison de lecteurs sur ces mêmes observations ne mesure plus l'avantage de leur collecte.

4 Protocole commun aux six expériences proposées

Les dossiers contiennent des observations expurgées de secrets réels et un contexte public documenté : rôle, ressource, politique, date et provenance. L'oracle privé conserve **deux étiquettes distinctes**. La première, $T_{\text{état}}$, décrit la propriété dans l'état de référence indépendant : « vrai », « faux » ou « inconnu ». La seconde, T_{preuve}, décrit ce que les observations du dossier permettent d'établir : « confirmable », « réfutable » ou « insuffisant ». Une propriété vraie dans la configuration peut rester insuffisamment documentée ; une abstention est alors correcte pour le lecteur. Un conflit non résolu peut aussi empêcher une conclusion. Une information manquante n'efface jamais l'étiquette d'état connue.

Barr et al. distinguent oracle partiel, vérité terrain et limites de justesse et de complétude [5]. Pour LANCE, proposer un double contrôle : conformité du verdict à la propriété réellement configurée et adéquation de ses références aux observations disponibles. Deux annotateurs, distincts des auteurs des méthodes, travaillent avec identifiants de méthode masqués ; les désaccords sont conservés puis arbitrés. La consigne et les cas litigieux sont versionnés. Le validateur commun du pipeline est un facteur de symétrie, pas l'unique oracle indépendant.

Chaque sortie comprend identifiant de propriété, verdict, références de preuves, contradictions, informations manquantes et motif d'abstention. Les références doivent pointer vers des observations fournies, pertinentes pour cette ressource, à cette date. Aucun score de confiance auto-déclaré ne remplace ce contrôle. Les métriques hors ligne sont nouvelles et doivent être documentées ; elles ne sont pas présentées comme le contrat courant `strict-v3`.

Le rappel d'état utilise comme dénominateur tous les positifs connus indépendamment sélectionnés, même si leur dossier est incomplet. Il décrit la restitution de cette population, affectée par la

couverture des observations. Le rappel conditionnel du lecteur utilise seulement les positifs connus dont la preuve est confirmable depuis le dossier. Une confirmation créditée exige un verdict juste et une référence de preuve adéquate. Publier les deux dénominateurs, la couverture documentaire, les abstentions et les erreurs : une abstention correcte sur preuve insuffisante reste visible dans le bilan global, sans être imputée à une faute d'interprétation. Les états inconnus et dossiers incomplets sont conservés avec leur statut.

L'unité de décision est la propriété d'un dossier ; l'unité de généralisation est sa famille d'origine, définie par générateur, services et structures techniques partagés, plutôt que par identifiant de scénario. Les répétitions LLM sont imbriquées dans le dossier, les variations dans la famille. Fixer répartition développement/test par famille avant de concevoir règles et prompts. Un test réservé aux auteurs ne certifie pas l'absence de contamination du préentraînement lorsque le corpus d'origine est public. Le problème de pseudoréplication décrit par Lazic motive cette prudence [3] ; ses résultats biologiques ne sont pas des estimations de dépendance pour notre corpus. Une nouvelle graine ou copie JSON ne crée pas une famille indépendante.

Les bras reçoivent exactement les mêmes octets utiles ou une normalisation équivalente vérifiée ; ordre d'exécution et de présentation sont équilibrés ou randomisés. Journaliser les coûts de toutes les tentatives, les erreurs de format, arrêts, exclusions et valeurs inconnues. L'absence de réseau dans une expérience hors ligne ne prouve aucune disponibilité des outils réels. Un budget total de temps/calcul est comparable ; les tokens servent uniquement à comptabiliser le bras qui utilise un modèle.

4.1 Fiche 1 — Contrôles routiniers

Question. Une procédure fixe ou des règles conditionnelles suffisent-elles à distinguer une configuration conforme d'une non-conformité connue ? **Données et entrée.** Dossiers de développement documentant configurations de service et réponses déjà enregistrées ; propriétés stables, cas conformes, non conformes et réponses incomplètes, y compris cas absents des candidats LANCE. **Sortie et oracle.** Verdict et preuve minimale pour chaque propriété, contrôlés contre configuration et observations indépendamment annotées.

Comparateurs et contrôles. Lecteur à règles fixes, lecteur conditionnel, puis lecteur LLM sur les mêmes dossiers ; sortie et normalisation communes. Un service simplement joignable ne constitue pas à lui seul une non-conformité. Les connaissances métier sont publiques et identiques. **Mesures et coûts.** Erreurs par propriété, précision et rappels d'état et conditionnel avec les dénominateurs définis ci-dessus, abstentions correctes, taux de preuves attribuées et temps/calcul, avec coût de construction des règles. **Arrêt et poursuite.** Suspendre le test si une différence de format ou de couverture explique le contraste. Poursuivre vers test réservé si les méthodes simples couvrent correctement les cas de développement ; rechercher alors leur éventuelle non-infériorité plutôt qu'une victoire imposée du LLM.

4.2 Fiche 2 — Contrôles sains et faible prévalence

Question. Le LLM apporte-t-il des alertes utiles sans produire davantage de fausses alertes lorsque les non-conformités sont rares ? **Données et entrée.** Dossiers conformes validés et proches cas non conformes, à partir d'une population définie indépendamment des sorties des méthodes. Prévalences par strate fixées avant test ; aucune distribution synthétique ne représente automatiquement un déploiement réel. **Sortie et oracle.** Liste d'alertes et abstentions avec preuve ; oracle privé vérifiant l'état conforme et les contrôles effectivement observés.

Comparateurs et contrôles. Lecteurs fixes, conditionnels et LLM ; même information. Ajouter réponses d'authentification refusée, contenu public inoffensif et observation manquante. Un dossier non analysé n'est pas un sain correctement reconnu. **Mesures et coûts.** Fausses alertes par

dossier et par propriété, spécificité avec dénominateur explicite, valeur prédictive positive à la prévalence déclarée, rappels d'état et conditionnel des rares cas positifs, et temps de tri humain. Les fausses alertes et la spécificité sont les mesures principales des contrôles sains. Pour $F1 = 2TP/(2TP + FP + FN)$, une strate saine avec $FP > 0$ donne zéro ; avec dénominateur nul, annoncer la convention choisie (valeur indéfinie dans ce protocole). Le silence universel est pénalisé sur les cas positifs. **Arrêt et poursuite.** Suspendre si les contrôles sains ne sont pas validés ou si l'extraction des cas dépend des alertes LANCE. Étendre seulement si la marge de fausses alertes préfixée peut être évaluée avec une précision utile.

4.3 Fiche 3 — Autorisation contextuelle

Question. Une politique explicite permet-elle des conclusions aussi justes qu'une lecture LLM du contexte d'autorisation ? **Données et entrée.** Matrice publique sujet–ressource–action–tenant, configuration fournie et traces préexistantes de décisions d'accès. Des cas partagent la même réponse technique mais des politiques légitimes différentes. **Sortie et oracle.** Relation entre accès observé et accès attendu, preuve associant identité, ressource et politique ; statut indéterminé si l'identité ou la portée de la politique n'est pas connue.

Comparateurs et contrôles. Règles conditionnelles avec table de politique, contre lecteur LLM recevant cette même table. D0 sert de repère, mais n'est pas le seul comparateur. Cas autorisé, refus conforme, accès contraire à la politique et identité absente sont présents ; les réponses HTTP seules ne déterminent pas le droit d'accès. **Mesures et coûts.** Classification de conformité, erreurs de liaison identité/ressource, abstention et coût d'encodage de la politique. **Arrêt et poursuite.** Suspendre si l'entrée publique contient l'étiquette privée de non-conformité. La matrice normative de droits est une entrée légitime et nécessaire aux deux bras ; sa présence n'est pas une fuite d'oracle. Généraliser uniquement à de nouvelles politiques réservées ; une victoire contre des règles privées du contexte ne serait pas un effet du modèle isolé.

4.4 Fiche 4 — Information répartie et contradictions

Question. Le LLM relie-t-il mieux des observations et repère-t-il des contradictions au-delà de jointures simples ? **Données et entrée.** Dossiers avec plusieurs observations référencées, identifiants de ressource et temps ; cas cohérents, contradictoires, périmés et incomplets. L'oracle associe les observations à la propriété pertinente, sans se limiter aux conclusions déjà proposées par LANCE. **Sortie et oracle.** Verdict, liens de preuve, contradictions et manque d'information ; l'oracle distingue conflit réel, ressources différentes et changement d'état documenté.

Comparateurs et contrôles. Règles conditionnelles sur un index tabulaire, puis, si besoin, jointures déterministes explicites ; lecteur LLM avec mêmes observations, clés, obligations et budget de lecture. Si un graphe est étudié, le contraste de représentation E0/E1 reste séparé de celui du lecteur. **Mesures et coûts.** Attribution valide, fausse fusion, contradictions repérées ou inventées, abstentions justifiées et temps/calcul ; coût de maintien des clés et des relations. **Arrêt et poursuite.** Suspendre si une méthode possède des obligations ou des observations supplémentaires. Garder l'index simple si les relations n'apportent aucun gain utile ; tester le lecteur LLM sur des compositions réservées seulement après une référence relationnelle crédible.

4.5 Fiche 5 — Variations équivalentes

Question. La qualité résiste-t-elle à une présentation différente qui préserve les mêmes faits et la même propriété de sécurité ? **Données et entrée.** Paires original/variation, approuvées indépendamment : ordre des champs, libellés publics équivalents, répartition en fichiers ou formulations de politique. Préserver identifiants et références ou publier leur correspondance ; ne

pas retirer une information à un seul bras. **Sortie et oracle.** Même verdict attendu et preuves correspondantes, avec conservation explicite des cas indéterminés.

Comparateurs et contrôles. Lecteurs à règles et LLM sur observations structurées communes ; seconde strate brute seulement pour tester les parseurs. Le test métamorphique exprime une relation attendue entre deux exécutions [5]. Il ne prouve pas qu'un verdict invariant est juste : les deux versions peuvent partager la même erreur. **Mesures et coûts.** Justesse absolue de chaque version, taux d'invariance, pertes de preuve et variation de l'écart LLM–règles par famille ; coûts de normalisation et de maintenance. **Arrêt et poursuite.** Exclure avec motif toute transformation ne préservant pas les faits. Dans la strate normalisée, une perte d'information due au parseur invalide le contraste sémantique ; suspendre ce contraste et corriger sa préparation. Dans la strate brute, l'échec de parsing reste un résultat de robustesse et son coût est conservé. Une réussite autorise une conclusion de robustesse aux transformations testées, pas de généralisation à de nouveaux protocoles.

4.6 Fiche 6 — Rapport et temps humain

Question. D1-R réduit-il le travail d'un auditeur à résultats techniques constants, sans augmenter les erreurs ? **Données et entrée.** Dossiers techniques gelés, comprenant preuves, limites et conclusions ; rapports par gabarit D1 et rédaction LLM D1-R. Tâches d'auditeur : retrouver une preuve, corriger un constat, prioriser une remédiation documentée. Plusieurs dossiers de familles différentes sont utilisés. **Sortie et oracle.** Réponse finale de l'auditeur et corrections, évaluées contre les mêmes résultats techniques ; aucune modification des détections.

Comparateurs et contrôles. Dossiers sources identiques et contraintes de production communes, notamment de longueur ; ordre équilibré, expérience des auditeurs consignée, affectation évitant qu'un lecteur revoie le même dossier avec l'autre rapport. Masquer l'origine des rapports autant que possible sans prétendre un aveugle parfait. Les effets auditeur et dossier restent distincts. **Mesures et coûts.** Temps actif, réussite des tâches, corrections, omission de réserves et affirmations inventées ; latence, consommation du modèle et temps de préparation/revue. Satisfaction seule ne suffit pas. **Arrêt et poursuite.** Suspendre si les dossiers sources ou les contraintes de production diffèrent, ou si le recrutement ne permet qu'un avis de l'auteur. Les omissions et affirmations inventées dans les rapports sont des erreurs mesurées et conservées dans le bilan, avec leurs coûts de revue et correction ; elles ne justifient pas l'exclusion d'un rapport. Cette tâche de lecture n'entraîne aucune décision sur un système réel. Conserver D1-R seulement si un gain humain utile est compatible avec les marges d'erreur ; le résultat concerne la restitution, indépendamment de la détection.

5 Mesures, décision et séquence réaliste

5.1 Un effet utile, une équivalence ou une conclusion indéterminée

Fixer une métrique principale et une portée par expérience avant le test final. Publier aussi les nombres bruts, les contrôles sains, les erreurs de preuve, les abstentions et la fraction de dossiers évaluables. Choisir les marges à partir du besoin d'audit et du développement : gain minimal utile, dégradation acceptable, coût et temps humain. Ce rapport ne leur attribue aucune valeur numérique prétendument validée.

Pour une métrique où une valeur élevée est meilleure, poser $\Delta = Q_{\text{LLM}} - Q_{\text{règles}}$. Si la borne inférieure de l'intervalle dépasse la marge utile préfixée, le gain peut soutenir l'usage du modèle, sous contraintes d'erreurs et de coût. Pour soutenir la non-infériorité des règles, l'hypothèse est que $Q_{\text{règles}} - Q_{\text{LLM}}$ reste au-dessus de la perte maximale tolérée négative. L'équivalence est bilatérale, autour de marges fixées avant test : l'intervalle approprié doit être entièrement compris entre ces

marges. Une différence non significative ne démontre aucune de ces deux propriétés [4]. Le choix de l'estimateur et de l'intervalle doit respecter les familles et le type de mesure ; copier un test t générique sur tous les constats dépendants serait insuffisant.

Proposer une analyse appariée, avec agrégation répétition → dossier → famille et pondération des familles annoncée à l'avance. Si les familles sont trop peu nombreuses pour l'inférence visée, publier un bilan descriptif et une conclusion indéterminée. La taille du test devra être justifiée après le développement, à partir de la variabilité observée et de marges opérationnelles, avec analyse de précision ou simulation adaptée. Le manifeste historique n'est pas une analyse de puissance.

Conserver toutes les tentatives dans le bilan opérationnel : échec de format, arrêt, budget dépassé ou dossier incomplet. Les métriques techniques manquantes restent inconnues, avec analyse de sensibilité prévue ; elles ne deviennent pas silencieusement zéro. Les conclusions tirées seulement des paires exploitables sont étiquetées conditionnelles. Les analyses secondaires et leurs éventuelles corrections de multiplicité sont déclarées avant le test.

5.2 Coût de construction, d'exploitation et de maintenance

Le comparateur actuel annonce un coût d'usage du LLM, sans mesurer toute l'infrastructure et le travail humain. Proposer le coût total explicite :

$$C(N, H) = C_{\text{construction}} + C_{\text{maintenance}}(H) + \sum_{i=1}^{N} (C_{\text{calcul},i} + C_{\text{modèle},i} + C_{\text{préparation/revue},i}).$$

N est le volume de dossiers ou d'audits et H l'horizon déclaré. Les règles et les prompts ont tous deux un coût de maintenance ; un prix API nul ne signifie pas un coût nul. Présenter heures et montants séparément, avec taux et scénarios d'amortissement documentés. Sculley et al. motivent le suivi des dépendances, configurations et changements externes [6], sans fournir un tarif ou une supériorité économique applicable à LANCE.

5.3 Ordre proposé et décisions possibles

La première livraison expérimentale serait le corpus annoté et un lecteur simple sur les fiches 1–2, puis le contraste de lecteurs sur observations identiques. Les fiches 3–4 ajoutent le contexte seulement quand il correspond à un besoin réel. La fiche 5 accompagne les comparaisons ; la fiche 6 nécessite une étude humaine distincte. Après gel, évaluer sur familles réservées sans retoucher règles et prompts sur les échecs du test. Une correction crée une nouvelle version et nécessite un nouveau test réservé.

Trois décisions sont recevables : garder les règles sur les tâches où elles suffisent selon les marges retenues ; réserver le LLM à une tâche pour laquelle un gain utile est mesuré ; ou conserver le résultat « indéterminé » quand la preuve manque. Si le modèle n'aide que la rédaction, D1-R peut être utile sans bénéfice de décision technique. Si l'aide tient surtout au développement de nouvelles règles, une étude séparée humain seul/humain assisté devra mesurer ce bénéfice de construction, avec exécution finale déterministe.

6 Limites et conclusion

Cette recherche ne démontre aucune performance comparative. La lecture statique ne prouve ni importabilité actuelle, ni disponibilité des outils, ni validité des configurations réellement déployées. Les conflits sont conservés ; les sources externes et les archives historiques ne réparent pas cette limite. La comparaison de lecteurs ne permet pas d'inférer la valeur d'un contrôleur adaptatif

complet. Les connaissances préentraînées du LLM restent un facteur inégalizable : le contraste mesure une méthode avec ses connaissances, pas le raisonnement pur.

Les premiers tests doivent établir la force et les limites des méthodes simples sur des dossiers indépendamment sélectionnés, avant de chercher des cas favorables au modèle. Les six fiches rendent ce programme réfutable : besoin défini, même information, oracle indépendant, coût complet et règle de décision avant les résultats. Une conclusion négative ou conditionnelle peut donner une contribution de thèse : délimiter les tâches où une automatisation simple suffit et celles où un LLM apporte une valeur mesurée.

Références

[1] LANCE. *Agent / automatisation*, protocole du 27 septembre 2026, suivi des 27–28 septembre, guides CLI/campagne et modules cités. Lecture statique le 7 octobre 2026 ; tests historiques non reproduits. `research/2026-09-27-agent-vs-automation/protocol.md`, `docs/benchmark/agent-vs-automation-cli.md` et `docs/benchmark/agent-vs-automation-campaign.md`.

[2] M. A. Hernán, J. M. Robins. *Causal Inference : What If*. 2020 ; version PDF du 26 avril 2024. Section 2.1 « Randomization » : extrait indexé du PDF primaire consulté le 7 octobre 2026 ; fichier complet inaccessible dans l'outil, autres chapitres non exploités. PDF primaire Harvard.

[3] S. E. Lazic. *The problem of pseudoreplication in neuroscientific studies : is it affecting your analysis ?* BMC Neuroscience 11 :5, 14 janvier 2010, doi :10.1186/1471-2202-11-5. Résumé, Background et sections sur observations répétées/hiérarchiques lus le 7 octobre 2026 ; résultats de neuroscience non transférés quantitativement. Article éditeur.

[4] D. Lakens. *Equivalence Tests : A Practical Primer for t Tests, Correlations, and Meta-Analyses*. Social Psychological and Personality Science 8(4) :355–362, 2017, doi :10.1177/1948550617697177. Version éditeur TU/e : Testing for Equivalence, Setting Equivalence Bounds et Discussion lus le 7 octobre 2026 ; aucune procédure statistique exécutée, adaptation aux mesures dépendantes de LANCE encore nécessaire. PDF éditeur déposé à TU/e.

[5] E. T. Barr, M. Harman, P. McMinn, M. Shahbaz, S. Yoo. *The Oracle Problem in Software Testing : A Survey*. IEEE TSE 41(5) :507–525, mai 2015, doi :10.1109/TSE.2014.2372785. Introduction, définitions, soundness/completeness lus dans le PDF UCL le 7 octobre 2026 ; techniques du corpus non reproduites. La métamorphie est présentée comme oracle partiel, sans validation d'une implémentation LANCE. PDF éditeur déposé à UCL.

[6] D. Sculley et al. *Hidden Technical Debt in Machine Learning Systems*. NIPS 28, 2015. Sections 3, 5–7 et 9 lues le 7 octobre 2026 ; discussion d'ingénierie sans mesure de coût spécifique LANCE. PDF des actes.