État des lieux de la plateforme LANCE et feuille de route vers AsiaCCS 2027

Architecture à changer, objectifs plateforme et métriques comportementales

Projet LANCE

Dernière révision : 2026-10-23 14:33 (Europe/Brussels, UTC+02:00)
Statut : état des lieux et propositions — aucun résultat expérimental nouveau

Résumé

Ce rapport consolide trois analyses menées en parallèle le 2026-10-12 (architecture, objectifs plateforme, métriques) en vue de la soumission visée à AsiaCCS 2027 (round 2). Il établit ce qui, dans l'architecture actuelle, doit changer pour rendre la contribution centrale prouvable, les objectifs mesurables que la plateforme doit atteindre, et les métriques comportementales à montrer au-delà des scores agrégés. Six chantiers sont jugés indispensables avant soumission, dont deux bloquants pour la preuve : le split par famille de packs et l'inférence statistique appariée, aujourd'hui absente. Aucun run de campagne n'ayant encore été exécuté, ce document ne rapporte aucune performance ; les efforts sont des estimations à confirmer.

Table des matières

1 Objectif et périmètre **1**

2 Architecture : ce qui doit changer **2**

3 Objectifs plateforme à atteindre **3**

4 Métriques comportementales : au-delà des scores **4**

5 Ce qu'il faut explicitement ne pas faire **5**

6 Limites et points non résolus **5**

7 Conclusion **5**

1 Objectif et périmètre

Ce document répond à trois questions, dans l'ordre où elles conditionnent la soumission : (1) en quoi l'architecture doit-elle changer pour que l'écart entre la politique à règles D1 (`rules`) et la politique à modèle A1 (`llm`) soit *prouvable* ; (2) quels objectifs la plateforme doit-elle atteindre, avec quels critères mesurables ; (3) quelles métriques *comportementales* montrer dans le papier, au-delà des meilleurs scores. La cible, les exigences de la conférence et les critères de décision sont fixés dans le dossier d'objectifs du projet (`objectifs/asiaccs-2027/`) ; les hypothèses H0–H3 et le protocole apparié sont ceux de la proposition compagne de ce dossier (`proposition-conditions.tex`). Ce rapport ne les recopient pas : il dit ce qui manque pour les exécuter.

Statut des sources : les affirmations d'implémentation proviennent d'une inspection du code et des documentations du dépôt à la date de révision, avec chemins cités. Deux des trois analyses parallèles se sont déclarées partielles ; leurs propositions sont donc présentées comme **à confirmer sur le code avant implémentation**, non comme des constats clos. Aucune expérience n'a été exécutée pour ce rapport.

Définitions minimales (autonomie de lecture). Seul le sélecteur de décision change entre les bras, le reste du pipeline (outils, inventaire, validateur) est identique : D1 suit des règles écrites, A1 laisse le modèle réviser ses décisions d'après les observations, A0 exécute un plan de modèle figé avant l'exécution, sans révision. Le seuil δ est l'écart minimal jugé utile, fixé avant le test. Un canari est un marqueur unique glissé dans chaque instance pour détecter une fuite du corpus de test. Les expériences sont E1 (carte des écarts par condition), E2 (adaptation : A0 figé contre A1, pentes sous bruit, hypothèse H2 de dégradation différentielle) et E3 (coût de l'avantage). Les packs `f11` (autorisation d'API) et `f20` (chemins réseau de pivot tenus à l'écart) sont deux familles de failles du catalogue.

2 Architecture : ce qui doit changer

Le tableau 1 classe les écarts par nécessité pour la soumission. Les efforts (S : moins d'un jour ; M : plusieurs jours à une semaine ; L : une à deux semaines) sont des estimations d'ordre de grandeur, pas des engagements.

Changement proposé	Effort	Justification et livrable
Split par famille de packs gelé avant tout test, canari unique par instance, journal d'accès	M	Le catalogue actuel (`benchmarks/catalog.yaml`)† répartit S1–S19 en `dev-public` et S20–S29 en `test-public` par scénario ; une même famille peut donc fuiter des deux côtés. Livrable : correspondance famille → dev/test vérifiée sans recouvrement.
Inférence appariée : intervalle de confiance à 95 % de Δ par famille, correction de Holm, résultats par famille	M	Le comparateur signale aujourd'hui `uncertainty.available=false` et la campagne reste descriptive (moyennes d'écarts). Sans inférence, le critère de décision de la proposition est inapplicable et la contribution centrale non prouvable.
Gel et exécution du pilote (12 paires, 24 runs)	S + exéc.	Le manifeste de campagne (`benchmarks/experiments/policy-comparison/`)† est modélisé mais non gelé : configuration vide, `run_dir` nuls, aucun run exécuté. Le pilote valide la mesure et calibre le seuil δ ; il ne produit pas le résultat du papier.
Bras A0 (plan de modèle figé) et second modèle dans le panneau de politiques	M	L'expérience d'adaptation E2 exige A0 contre A1 à préfixe identique ; le panneau minimal exige D1 plus au moins deux modèles. Les champs de traitement et de paire existent déjà dans le comparateur ; les politiques elles-mêmes restent à étendre, avec ordre randomisé par blocs et au moins trois graines.
Variantes minimales déployables : pack logique `f11` et chemins tenus à l'écart `f20`	L	Parmi 22 définitions de packs, ce sont les deux strates qui conditionnent la nouveauté et les failles logiques. Chaque variante exige la correspondance spécification ↔ services déployés ↔ sondes ↔ vérité terrain ; une altération seulement prévue invalide la strate.
Artefact anonymisé portable (extrait émulé d'une famille, hors Proxmox/NATO)	L (tôt)	L'appendice Open Science est obligatoire à AsiaCCS, avec lien anonymisé accessible pendant la revue. Aucun mode émulé portable n'existe aujourd'hui. Livrable : extrait minimal reproductible plus justification explicite du reste non partageable.

Table 1 – Changements d'architecture proposés avant soumission, par nécessité. Propositions issues des analyses du 2026-10-12, à confirmer sur le code ; efforts estimés. † Fait revérifié par lecture directe le 2026-10-12.

Ce qui est déjà en place et à conserver : le sélecteur de modes (`src/agent/run_modes.py`) isole la politique de décision ; le comparateur (`src/benchmark/compare_policies.py`) produit les écarts appariés, conserve les scores par bras, refuse les valeurs manquantes remplacées par zéro et émets des motifs d'incomparabilité explicites ; le journal d'exécution relie chaque appel d'outil à sa source de décision. Le pipeline six phases est l'instrument de mesure ; il n'est pas à reconstruire.

3 Objectifs plateforme à atteindre

Trois objectifs, formulés en critères mesurables, portent les contributions candidates du papier. Chacun dit ce qui le réfute ou l'invalide.

C1 — Benchmark tenu à l'écart.
Corpus gelé par famille, canaris par instance, variantes déployées et vérifiées. Critère : aucune famille de test présente dans les règles, prompts ou exemples ; journal d'accès complet ; quatre contrôles négatifs propres (scénario sans faille, preuves invalides rejetées des deux côtés, leurre à motif connu non exploitable, canari non régurgité). Un contrôle en échec invalide le lot.

C2 — Carte des écarts.
Écart apparié A1−D1 en vrais positifs confirmés par le contrat strict-v3 (confirmation par

traces d'exécution vérifiées, jamais par étiquette de rapport), par condition expérimentale. Succès : borne inférieure de l'intervalle à 95 % supérieure à δ après correction de Holm dans au moins une condition prédite. Une carte vide mais bornée (intervalles étroits autour de zéro) reste un résultat publiable repositionné.

C3 — Coût de l'avantage.
Sur les mêmes runs : coût par vrai positif confirmé, temps par jalon, variance inter-graines (au moins trois graines, jamais moyennée en silence), grille de prix gelée avant le test. Un avantage à plus de trois fois le coût des règles borne la revendication à un usage semi-autonome.

S'y ajoute l'expérience d'adaptation E2 (A0 figé contre A1 adaptatif, pentes de dégradation sous bruit par bras) et le rappel que le pilote de 24 runs valide la mesure et calibre δ et la puissance ; aucun de ses chiffres n'entre dans les tableaux du papier.

La figure 1 place ces chantiers sur la fenêtre disponible jusqu'à la décision.

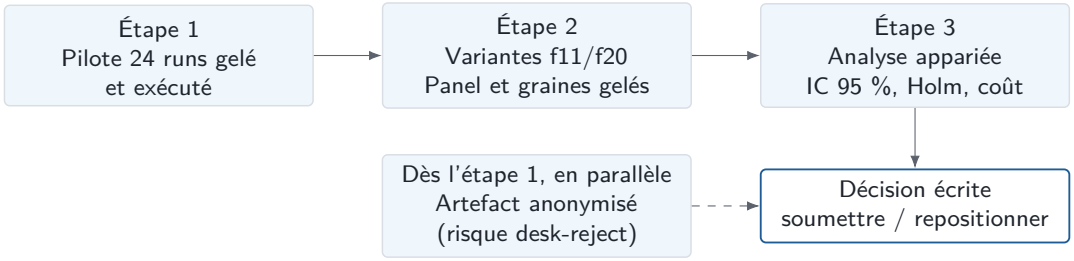


Figure 1 – Feuille de route proposée jusqu'à la décision. Calendrier de travail, pas un résultat ; les critères de la décision sont ceux du dossier d'objectifs.

4 Métriques comportementales : au-delà des scores

Un score agrégé (F1 final) cache exactement ce que le papier cherche à établir : *comment* chaque politique se comporte quand le monde résiste. Trois familles de métriques sont à montrer.

Déjà instrumentées, à conserver. L'entonnoir par stade (candidats, filtrés, confirmés ; vrais/faux positifs et négatifs, précision, rappel, F1, preuves invalides), la spécificité dont celle des contrôles négatifs, le coût total (jetons, tours, appels et erreurs d'outils), la durée murale et le coût par vrai positif confirmé existent dans le comparateur. Les ratios à dénominateur nul restent indéfinis et visibles, jamais remplacés par zéro.

À instrumenter (trous actuels). Taux de rejet de preuve par bras (la politique propose-t-elle des constats que strict-v3 refuse ?) ; taux de runs évaluables et causes terminales par bras ; temps au premier vrai positif confirmé et temps par jalon ; pentes $S(n)$ de dégradation quand le nombre n de leurres augmente, *par bras* (c'est la mesure directe de l'adaptation, hypothèse H2) ; variance inter-graines rapportée en distribution ; compteur de canaris régurgités. La grille de jalons (analyse $\rightarrow$ vérification $\rightarrow$ preuve $\rightarrow$ accès, crédit 0–1) est à geler avant le test, avec le garde-fou suivant : un gain en jalons sans gain en vrais positifs confirmés vaut inflation de progression, pas avantage.

Comparabilité comme métrique. Chaque paire doit journaliser pourquoi elle est comparable ou non (inventaire, source CVE, mémoire, versions de preuve) ; seuls la politique, le fournisseur et le modèle peuvent différer. Aucun écart n'est émis pour une paire non comparable. Une revue aveugle des preuves, sans colonne de politique, complète le dispositif.

Ces métriques servent la lecture comportementale recherchée : deux politiques à F1 égal peuvent différer par le temps au premier succès, la fragilité sous bruit, le taux de preuves rejetées et le coût marginal du dernier vrai positif — c'est cette différence, si elle existe, qui constitue le résultat.

5 Ce qu'il faut explicitement ne pas faire

Trois garde-fous bornent le périmètre. *Portée* : pas de nouveau système (l'instrument suffit), pas de double soumission simultanée, pistes bonus (modèle à mélange d'experts comme second sujet, phases 2 et 5, génération procédurale complète, scénarios à impasses) hors chemin critique tant que E1–E3 ne sont pas bouclées. *Méthode* : ne jamais affaiblir volontairement la référence à règles, ne pas recalibrer δ après observation du test, ne pas interpréter un lot dont un contrôle négatif a échoué, ne pas reformuler après coup un résultat nul ou trivial. *Revendications* : les modes `vanilla` et `scripted` ne produisent pas de scores de benchmark ; aucune réduction du travail humain n'est inférée sans étude dédiée avec auditeurs.

6 Limites et points non résolus

Aucun run de campagne n'a été exécuté : la puissance réelle et la valeur de δ restent non calibrées. L'indépendance historique du split actuel S20–S29 n'est pas vérifiée, ce qui motive le split par famille sans le rendre acquis. Le mode émulé portable hors laboratoire NATO n'existe pas ; sa faisabilité et l'écart tolérable avec le laboratoire Proxmox sont à prouver sur une famille. Le panneau de modèles (second modèle, éventuel modèle à mélange d'experts) et le bras A0 restent à geler avant l'étape 3. Enfin, deux des trois analyses consolidées ici se déclaraient partielles : chaque changement du tableau 1 doit être confirmé sur le code avant implémentation.

7 Conclusion

La plateforme est, pour l'essentiel, déjà l'instrument qu'il faut ; ce qui manque se concentre en deux prouves (split par famille, inférence appariée), une exécution (le pilote), et un artefact partageable. La décision, prise sur les critères écrits du dossier d'objectifs, dira si ces éléments suffisent à soumettre à AsiaCCS, à repositionner le papier en mesure à résultat négatif, ou à différer vers un workshop puis une version élargie. La prochaine action est le gel du pilote, pas une fonctionnalité nouvelle.